

BayesianDEB: Bayesovsko modeliranje dinamičke energetske bilance u R-u

Priručnik s primjerima (verzija 0.1.0)

Branimir K. Hackenberger

Travanj 2026.

Sažetak

BayesianDEB je R paket koji pruža cjelovit Bayesovski okvir za modeliranje dinamičke energetske bilance (eng. Dynamic Energy Budget, DEB). Paket obuhvaća pripremu podataka, specifikaciju priora i modela opažanja, MCMC procjenu parametara putem **Stan**-a, dijagnostiku konvergencije, posteriorne prediktivne provjere, izračun izvedenih veličina te vizualizaciju rezultata. Uključena su četiri tipa modela: individualni rast, rast s reprodukcijom, hijerarhijski model s djelomičnim spajanjem te DEBtox (toksikokinetičko-toksikodinamički) model za ekotoksikologiju. Ovaj dokument opisuje sve funkcionalnosti paketa i sadrži detaljne primjere za svaki tip modela.

Sadržaj

1	Uvod	2
2	Instalacija	2
3	Kratki pregled DEB teorije	2
4	Arhitektura paketa	4
4.1	Ugrađeni Stan modeli	4
4.2	Radni tok	4
5	Priprema podataka	5
5.1	bdeb_data() — Priprema podataka za BDEB modele	5
5.2	repro_to_intervals() — Pretvorba kumulativne reprodukcije u intervale	6
6	Specifikacija priora	7
6.1	Konstruktori priora	7
6.2	prior_default() — Zadani slabo informativni priori	8
7	Modeli opažanja	9
8	Specifikacija modela	9
8.1	bdeb_model() — Specifikacija BDEB modela	9
8.2	Validacija tipa i podataka	10
9	Procjena modela (MCMC)	11
9.1	bdeb_fit() — Procjena BDEB modela	11

10	Dijagnostika konvergencije	12
10.1	bdeb_diagnose() — MCMC dijagnostika	12
10.2	bdeb_summary() — Posteriorna sumarizacija	12
11	Izvedene veličine	13
11.1	bdeb_derived() — Biološki značajne izvedene veličine	13
12	Posteriorne prediktivne provjere (PPC)	13
12.1	bdeb_ppc() — Provjera modela	13
12.2	bdeb_predict() i predict.bdeb_fit() — Predikcije	14
13	Vizualizacija	14
13.1	plot(fit, type = ...) — Grafički prikazi procjene	14
13.1.1	Trace grafovi	14
13.1.2	Posteriorne gustoće	15
13.1.3	Dijagrami parova	15
13.1.4	Trajektorije	15
13.2	plot(ppc) — Grafički prikaz PPC-a	15
14	DEBtox: Ekotoksikološki modeli	15
14.1	Teorijska pozadina	16
14.2	Dodatni DEBtox parametri	16
14.3	bdeb_tox() — Specifikacija DEBtox modela	16
14.4	bdeb_ec50() — Ekstrakcija EC50 i NEC	17
14.5	plot_dose_response() — Krivulja doza-odgovor	17
15	Pomoćne funkcije	18
15.1	arrhenius() — Arrheniusova temperaturna korekcija	18
15.2	deb_fluxes() — Izračun DEB energetskih tokova	18
16	Ugrađeni skupovi podataka	19
16.1	eisenia_growth	19
16.2	folsomia_repro	20
16.3	debtox_growth	20
17	Cjeloviti primjeri: Radni tokovi za sve tipove modela	21
17.1	Primjer 1: Individualni model rasta	21
17.2	Primjer 2: Hijerarhijski model s više jedinki	23
17.3	Primjer 3: Model rasta i reprodukcije	24
17.4	Primjer 4: DEBtox ekotoksikološki model	25
18	Detalji Stan modela	27
18.1	Desna strana DEB ODE sustava	27
18.2	Hiperparametri priora kao podaci	27
18.3	Necentrirana parametrizacija hijerarhijskog modela	28
18.4	Generated quantities	28
19	Praktični savjeti	28
19.1	Odabir adapt_delta	28
19.2	Kada koristiti hijerarhijski model	29
19.3	Osjetljivost na priore	29
19.4	Računalni savjeti	29

20 Usporedba s postojećim alatima	29
21 Pregled svih eksportiranih funkcija	29

1 Uvod

Teorija dinamičke energetske bilance (DEB) pruža mehanistički, termodinamički konzistentan opis načina na koji organizmi apsorbiraju i koriste energiju za održavanje, rast, razvoj i reprodukciju. Klasična DEB kalibracija oslanja se na determinističku optimizaciju—pronalaženje jednog najboljeg skupa parametara—što ne daje formalnu kvantifikaciju nesigurnosti i ne može prirodno uključiti prethodno biološko znanje ili hijerarhijske podatkovne strukture.

BayesianDEB rješava ta ograničenja ugrađivanjem DEB sustava diferencijalnih jednadžbi unutar Bayesovskog state-space okvira. Parametri se tretiraju kao slučajne varijable s apriornim distribucijama; funkcija vjerodostojnosti konstruira se iz modela opažanja koji povezuju latentna DEB stanja s mjerenim veličinama; a posteriorna distribucija istražuje se pomoću Hamiltonskog Monte Carlo (HMC) algoritma putem Stan-a.

Radni tok paketa slijedi iterativni Bayesovski ciklus modeliranja:

1. Priprema i validacija podataka.
2. Specifikacija DEB procesnog modela, priora i modela opažanja.
3. Procjena modela putem MCMC-a.
4. Dijagnostika konvergencije.
5. Posteriorne prediktivne provjere.
6. Izračun izvedenih veličina i predikcija.
7. Po potrebi, revizija modela.

2 Instalacija

BayesianDEB zahtijeva **cmdstanr** i funkcionalnu CmdStan instalaciju za procjenu modela. Funkcije za pripremu podataka, specifikaciju priora i pomoćne funkcije rade i bez Stan-a.

```
# 1. Instalacija cmdstanr paketa iz Stan r-universe repozitorija
install.packages("cmdstanr",
  repos = c("https://stan-dev.r-universe.dev",
            getOption("repos")))

# 2. Instalacija CmdStan prevoditelja (jednokratno, ~2 min)
cmdstanr::install_cmdstan()


# 3. Instalacija BayesianDEB paketa
install.packages("BayesianDEB")
# ili iz izvornog koda:
# remotes::install_github("bhackenberger/BayesianDEB")

# 4. Ucitavanje paketa
library(BayesianDEB)
```

3 Kratki pregled DEB teorije

Standardni DEB model prati četiri varijable stanja kroz vrijeme:

- E — energija rezervi (J),
- V — strukturni volumen (cm^3), sa strukturnom duljinom $L = V^{1/3}$,
- E_H — zrelost (J),
- E_R — reproduktivni spremnik (J).



Slika 1: Shema tokova energije u standardnom DEB modelu (κ -pravilo). Energija iz hrane ulazi u rezervu E , mobilizira se i dijeli κ -pravilom: udio κ ide na somatsko održavanje i rast strukture V , a ostatak $(1-\kappa)$ na održavanje zrelosti i reprodukciju E_R .

Tokovi energije upravljaju se κ -pravilom: udio κ mobilizirane rezerve odlazi na somatsko održavanje i rast, a ostatak na održavanje zrelosti i reprodukciju. Ključni tokovi su:

$$\dot{p}_A = f \{p_{Am}\} L^2 \quad (\text{asimilacija}), \quad (1)$$

$$\dot{p}_C = \frac{E v L}{E + [E_G] V} \quad (\text{mobilizacija}), \quad (2)$$

$$\dot{p}_M = [p_M] V \quad (\text{somatsko održavanje}), \quad (3)$$

$$\frac{dE}{dt} = \dot{p}_A - \dot{p}_C, \quad (4)$$

$$\frac{dV}{dt} = \frac{\kappa \dot{p}_C - \dot{p}_M}{[E_G]}, \quad (5)$$

$$\frac{dE_R}{dt} = (1 - \kappa) \dot{p}_C - \dot{p}_J. \quad (6)$$

Tablica 1 prikazuje standardne DEB parametre korištene u ovom paketu.

Tablica 1: Standardni DEB parametri u paketu **BayesianDEB**.

Simbol	R ime	Jedinice	Opis
$\{p_{Am}\}$	p_Am	$\text{J d}^{-1} \text{cm}^{-2}$	Maks. specifična stopa asimilacije po površini
$[p_M]$	p_M	$\text{J d}^{-1} \text{cm}^{-3}$	Volumno-specifična stopa somatskog održavanja
κ	kappa	–	Udio alokacije na somu
v	v	cm d^{-1}	Energetska vodljivost
$[E_G]$	E_G	J cm^{-3}	Specifični trošak strukture
k_J	k_J	d^{-1}	Stopa održavanja zrelosti
E_H^p	E_Hp	J	Zrelost pri pubertetu
f	f_food	–	Skalirani funkcionalni odgovor (0–1)
E_0	E0	J cm^{-3}	Početna gustoća rezervi
L_0	L0	cm	Početna strukturna duljina
σ_L	sigma_L	cm	Standardna devijacija pogreške opažanja

4 Arhitektura paketa

BayesianDEB se sastoji od tri sloja:

Stan modeli

Unaprijed napisani `.stan` programi u direktoriju `inst/stan/` koji implementiraju DEB ODE sustav i Bayesovsku inferenciju. Korisnici nikada ne trebaju izravno uređivati Stan kod.

R sučelje

Eksportirane funkcije za pripremu podataka, specifikaciju modela, procjenu, dijagnostiku i vizualizaciju. Sve funkcije koriste S3 klase (`bdeb_data`, `bdeb_model`, `bdeb_fit`).

Sustav priora

Obitelj `prior_*`() konstruktorskih funkcija koje kodiraju izbor distribucije kao lagane objekte proslijeđene funkciji `bdeb_model()`.

4.1 Ugrađeni Stan modeli

Tablica 2: Stan modeli ugrađeni u paket **BayesianDEB**.


Stan datoteka	Stanja	R tip	Primjena
<code>bdeb_individual_growth</code>	E, V	"individual"	Rast jednog organizma
<code>bdeb_growth_repro</code>	E, V, R	"growth_repro"	Rast + reprodukcija
<code>bdeb_hierarchical_growth</code>	$E, V + RE$	"hierarchical"	Više jedinki, djelomično spajanje
<code>bdeb_debtox</code>	E, V, R, D_w	"debtox"	Ekotoksikologija (TKTD)

Svi Stan modeli koriste BDF (eng. backward differentiation formula) rješavač krutih ODE sustava (`ode_bdf`) s tolerancijama 10^{-6} i maksimalno 10 000 koraka, što je primjereno za razdvajanje vremenskih skala tipično za DEB dinamiku rezervi i strukture.

4.2 Radni tok

Cjelokupni radni tok paketa može se sažeti sljedećim nizom poziva:

```
bdeb_data() -> bdeb_model() -> bdeb_fit() -> bdeb_diagnose()
                                         -> bdeb_ppc()
                                         -> bdeb_derived()
                                         -> plot()
```



Slika 2: Radni tok paketa **BayesianDEB**. Isprekidana strelica označava iterativnu reviziju modela na temelju dijagnostike.

5 Priprema podataka

5.1 bdeb_data() — Priprema podataka za BDEB modele

Funkcija `bdeb_data()` pretvara podatkovne okvire u dugom formatu u strukturirani format koji zahtijevaju Stan modeli. Provodi validaciju naziva stupaca, sortira po jedinkama i vremenu te konstruira interni S3 objekt klase `bdeb_data`.

```
bdeb_data(growth = NULL, reproduction = NULL,  
          survival = NULL, concentration = NULL,  
          f_food = 1.0)
```

Argumenti.

growth	Podatkovni okvir sa stupcima <code>id</code> , <code>time</code> , <code>length</code> . Opcionalno i stupac <code>weight</code> .
reproduction	Podatkovni okvir sa stupcima <code>id</code> , <code>t_start</code> , <code>t_end</code> , <code>count</code> .
survival	Podatkovni okvir sa stupcima <code>id</code> , <code>time</code> , <code>event</code> (1 = smrt, 0 = cenzurirano).
concentration	Imenovani numerički vektor ili podatkovni okvir koji mapira ID-ove na vanjske koncentracije toksikanta (za DEBtox modele).
f_food	Skalirani funkcionalni odgovor, $f \in [0, 1]$. Zadano 1 (ad libitum hranjenje).

Vraća. Objekt klase `bdeb_data` (lista).

Primjer: jednostavni podaci o rastu.

```
library(BayesianDEB)  
  
df <- data.frame(  
  id      = rep(1, 10),  
  time    = seq(0, 45, by = 5),  
  length  = c(0.10, 0.15, 0.22, 0.30, 0.38,  
              0.44, 0.49, 0.52, 0.54, 0.55)  
)  
dat <- bdeb_data(growth = df)  
dat  
# -- BDEB Data ---  
# i Individuals: 1  
# i Endpoints: growth  
# i Functional response (f): 1  
# > Growth: 10 observations, t = [0, 45]
```

Primjer: korištenje ugrađenog dataseta.

```
data(eisenia_growth)  
head(eisenia_growth)  
#   id time length  
# 1  1    0 0.1023  
# 2  1    7 0.1487  
# ...  
  
# Jedna jedinka  
dat1 <- bdeb_data(  
  growth = eisenia_growth[eisenia_growth$id == 1, ],  
  f_food = 1.0  
)  
  
# Sve jedinke (za hijerarhijski model)
```

```
dat_all <- bdeb_data(growth = eisenia_growth, f_food = 1.0)
dat_all
# => 21 jedinka, 273 žopaanja
```

Primjer: kombinacija rasta i reprodukcije.

```
growth_df <- data.frame(
  id = 1, time = seq(0, 56, by = 7),
  length = c(0.10, 0.18, 0.28, 0.37, 0.44,
             0.49, 0.52, 0.54, 0.55)
)
repro_df <- data.frame(
  id      = 1,
  t_start = c(28, 35, 42, 49),
  t_end   = c(35, 42, 49, 56),
  count   = c(5, 12, 18, 15)
)
dat_gr <- bdeb_data(growth = growth_df,
                    reproduction = repro_df,
                    f_food = 1.0)
dat_gr
# => Endpoints: growth, reproduction
```

Primjer: podaci s koncentracijama (za DEBtox).

```
data(debttox_growth)

# Imenovanje koncentracijskih grupa
conc_map <- setNames(
  c(0, 20, 80, 200),
  as.character(unique(debttox_growth$concentration))
)

dat_tox <- bdeb_data(
  growth = debttox_growth,
  concentration = conc_map,
  f_food = 1.0
)
dat_tox
# => Concentration groups: 4
```

5.2 repro_to_intervals() — Pretvorba kumulativne reprodukcije u intervale

Mnogi eksperimenti bilježe kumulativni broj potomaka. Funkcija `repro_to_intervals()` pretvara takve podatke u intervalne brojeve prikladne za argument `reproduction` funkcije `bdeb_data()`.

```
repro_to_intervals(df)
```

Argumenti.

df Podatkovni okvir sa stupcima `id`, `time`, `cumulative`.

Vraća. Podatkovni okvir sa stupcima `id`, `t_start`, `t_end`, `count`.

```
cumul <- data.frame(
  id      = rep(1, 5),
  time    = c(0, 7, 14, 21, 28),
```



```

    cumulative = c(0, 10, 30, 60, 100)
  )
  intervals <- repro_to_intervals(cumul)
  intervals
#   id t_start t_end count
# 1  1      0     7    10
# 2  1      7    14    20
# 3  1     14    21    30
# 4  1     21    28    40

```

6 Specifikacija priora

Priorne distribucije specificiraju se putem konstruktorskih funkcija koje vraćaju objekte klase `bdeb_prior`. Ti se objekti predaju kao imenovana lista funkciji `bdeb_model()`; svi nespecificirani priori automatski se popunjavaju iz funkcije `prior_default()`.


6.1 Konstruktori priora

Paket nudi šest priornih distribucija prilagođenih različitim tipovima DEB parametara:

Funkcija	Distribucija	Argumenti	Preporučeno za
<code>prior_lognormal()</code>	$\text{LogNormal}(\mu, \sigma)$	<code>mu</code> , <code>sigma</code>	Pozitivni parametri stope
<code>prior_normal()</code>	$\mathcal{N}(\mu, \sigma)$	<code>mu</code> , <code>sigma</code>	Neograničeni parametri
<code>prior_beta()</code>	$\text{Beta}(a, b)$	<code>a</code> , <code>b</code>	Parametri na $(0, 1)$
<code>prior_halfnormal()</code>	$\text{HalfNormal}(\sigma)$	<code>sigma</code>	Parametri skale
<code>prior_halfcauchy()</code>	$\text{HalfCauchy}(\sigma)$	<code>sigma</code>	Skala (teži repovi)
<code>prior_exponential()</code>	$\text{Exp}(\lambda)$	<code>rate</code>	Hijerarhijske varijance

Preporuke za izbor priora.

- **Pozitivni parametri stope** ($\{p_{Am}\}$, $[p_M]$, v , $[E_G]$, k_J , k_d , z_w , b_w): koristiti `prior_lognormal()`.
- **Udio alokacije** (κ): koristiti `prior_beta()`.
- **Standardna devijacija pogreške** (σ_L): koristiti `prior_halfnormal()`.
- **Hijerarhijske komponente varijance**: koristiti `prior_exponential()`.



Slika 3: Oblici zadanih priornih distribucija korištenih u paketu: log-normalna za pozitivne parametre stope (lijevo), Beta za udio alokacije κ (sredina), polu-normalna za parametre skale (desno).

Primjeri konstruktora.

```

# Log-normalni prior na stopu asimilacije
p1 <- prior_lognormal(mu = 1.5, sigma = 0.5)

```

```

p1$family # "lognormal"
p1$mu     # 1.5

# Beta prior na kappu
p2 <- prior_beta(a = 3, b = 2)

# Polu-normalni prior na pogresku opazanja
p3 <- prior_halfnormal(sigma = 0.05)

# Eksponencijalni prior za hijerarhijsku varijancu
p4 <- prior_exponential(rate = 2)

# Normalni prior (za necentrirane parametre)
p5 <- prior_normal(mu = 1.5, sigma = 0.5)

# Polu-Cauchyjev prior (za robusnije repove)
p6 <- prior_halfcauchy(sigma = 1)

```

6.2 prior_default() — Zadani slabo informativni priori

Funkcija `prior_default()` vraća kompletnu imenovanu listu slabo informativnih priora prikladnih za zadani tip modela.

```

prior_default(type = c("individual", "growth_repro",
                       "hierarchical", "debttox"))

```

Tablica 4 prikazuje zadane priore za individualni model rasta.

Tablica 4: Zadani priori za individualni model rasta.

Parametar	Prior	Obrazloženje
p_Am	LogNormal(1.0, 1.0)	Pokriva raspon ~ 0.4 –20
p_M	LogNormal(−1.0, 1.0)	Pokriva raspon ~ 0.04 –2
kappa	Beta(2, 2)	Favorizira unutarnje vrijednosti
v	LogNormal(−1.5, 1.0)	Pokriva raspon ~ 0.02 –1
E_G	LogNormal(6.0, 1.0)	Pokriva ~ 100 –3000
E0	LogNormal(0.0, 1.0)	Početna gustoća rezervi
L0	LogNormal(−2.0, 1.0)	Početna duljina ~ 0.01 –0.5
sigma_L	HalfNormal(0.1)	SD pogreške mjerenja

Dodatni priori za specifične tipove modela:

- "growth_repro" dodaje: `k_J`, `E_Hp`, `k_R` (pretvorba reproduktivnog spremnika u potomke), `phi_R` (overdispersija za negativnu binomnu).
- "hierarchical" dodaje: `mu_log_p_Am` ($\mathcal{N}(1.0, 1.0)$), `sigma_log_p_Am` ($\text{Exp}(1.0)$).
- "debttox" dodaje: `k_d` (stopa oporavka štete), `z_w` (NEC), `b_w` (intenzitet učinka).

```

# Pregled zadanih priora za svaki tip modela
prior_default("individual")
prior_default("growth_repro")
prior_default("hierarchical")
prior_default("debttox")

```

7 Modeli opažanja

Modeli opažanja definiraju vezu između latentnih DEB stanja i mjerenih podataka. Specificiraju se putem konstruktorskih funkcija i predaju argumentu `observation` funkcije `bdeb_model()`.

Funkcija	Distribucija	Zadano za	Primjena
<code>obs_normal()</code>	$\mathcal{N}(\hat{L}, \sigma_L)$	Rast	Kontinuirani podaci
<code>obs_lognormal()</code>	$\text{LogNormal}(\log \hat{L}, \sigma)$	–	Multiplikativna pogreška
<code>obs_student_t()</code>	$t_\nu(\hat{L}, \sigma_L)$	–	Robusnost na stršće vrijednosti
<code>obs_poisson()</code>	$\text{Poisson}(\Delta R)$	–	Brojčani podaci
<code>obs_negbinom()</code>	$\text{NegBin}(\Delta R, \phi)$	Reprodukcija	Overdispersirani brojevi

```
# Zadani modeli opažanja
obs_normal()           # za rast (Gaussovska pogreska)
obs_negbinom()         # za reprodukciju (negativna binomna)

# Alternativni izbori
obs_lognormal()        # multiplikativna pogreska
obs_student_t(nu = 5)  # robusno na strsece vrijednosti
obs_poisson()          # za rijetke dogadjaje
```

8 Specifikacija modela

8.1 `bdeb_model()` — Specifikacija BDEB modela

Funkcija `bdeb_model()` kombinira podatke, tip DEB modela, priore i model opažanja u jedinstvenu specifikaciju. Ne provodi procjenu modela—za to služi `bdeb_fit()`.

```
bdeb_model(data, type = c("individual", "growth_repro",
                          "hierarchical", "debttox"),
           priors = list(), observation = list(),
           temperature = NULL)
```

Argumenti.

data	Objekt <code>bdeb_data</code> kreiran s <code>bdeb_data()</code> .
type	Tip modela (tablica 2).
priors	Imenovana lista <code>bdeb_prior</code> objekata. Nespecificirani priori popunjavaju se iz <code>prior_default()</code> .
observation	Imenovana lista modela opažanja. Zadano: <code>growth = obs_normal()</code> , <code>reproduction = obs_negbinom()</code> .
temperature	Opcionalna lista s komponentama T (temperatura opažanja u K), T_ref (referentna temperatura), T_A (Arrheniusova temperatura) za temperaturnu korekciju.

Vraća. Objekt klase `bdeb_model`.

Primjer: individualni model s prilagođenim priorima.

```
data(eisenia_growth)
df1 <- eisenia_growth[eisenia_growth$id == 1, ]
dat <- bdeb_data(growth = df1)

mod <- bdeb_model(dat, type = "individual",
```

```

priors = list(
  p_Am = prior_lognormal(mu = 1.5, sigma = 0.5),
  p_M = prior_lognormal(mu = -1.0, sigma = 0.5),
  kappa = prior_beta(a = 3, b = 2),
  sigma_L = prior_halfnormal(sigma = 0.05)
))
mod
# -- BDEB Model Specification ---
# i Type: individual
# i Stan model: bdeb_individual_growth
# i Individuals: 1
# -- Priors --
# p_Am: LogNormal(1.5, 0.5)
# kappa: Beta(3.0, 2.0)
# ...

```

Primjer: hijerarhijski model sa zadanim priorima.

```

dat_all <- bdeb_data(growth = eisenia_growth)
mod_h <- bdeb_model(dat_all, type = "hierarchicall")
# Svi priori automatski popunjeni iz prior_default("hierarchicall")
mod_h

```

Primjer: model rasta i reprodukcije.

```

dat_gr <- bdeb_data(growth = growth_df,
  reproduction = repro_df)
mod_gr <- bdeb_model(dat_gr, type = "growth_repro",
  priors = list(
    kappa = prior_beta(a = 3, b = 2),
    k_R = prior_lognormal(mu = -2, sigma = 1)
  ))

```

8.2 Validacija tipa i podataka

Funkcija `bdeb_model()` automatski provjerava kompatibilnost tipa modela s dostupnim podacima:


- "individual": upozorava ako postoji više od jedne jedinke (koristi samo prvu).
- "growth_repro": zahtijeva podatke o reprodukciji.
- "debtox": zahtijeva podatke o koncentracijama.

```

# Ovo ce javiti gresku jer nema podataka o reprodukciji:
# bdeb_model(dat, type = "growth_repro")

# Ovo ce javiti gresku jer nema podataka o koncentracijama:
# bdeb_model(dat, type = "debtox")

```



Slika 4: Četiri tipa modela u paketu **BayesianDEB**. E = rezerva, V = struktura, R = reproduktivni spremnik, D_w = skalirana unutarnja šteta, μ, σ = populacijski hiperparametri.

9 Procjena modela (MCMC)

9.1 bdeb_fit() — Procjena BDEB modela

Funkcija `bdeb_fit()` kompilira Stan model (ako je potrebno) i pokreće MCMC uzorkovanje putem `cmdstanr`-a.

```
bdeb_fit(model, chains = 4, iter_warmup = 1000,
         iter_sampling = 1000, adapt_delta = 0.8,
         max_treedepth = 10, seed = NULL,
         parallel_chains = NULL, refresh = 200, ...)
```

Ključni argumenti.

model	Objekt <code>bdeb_model</code> .
chains	Broj MCMC lanaca. Zadano 4.
iter_warmup	Broj iteracija zagrijavanja po lancu. Zadano 1000.
iter_sampling	Broj iteracija uzorkovanja po lancu. Zadano 1000.
adapt_delta	Ciljna prosječna vjerojatnost prihvatanja. Zadano 0.8. Povećati prema 1.0 ako se pojave divergencije.
max_treedepth	Maksimalna dubina stabla za NUTS. Zadano 10.
seed	Sjeme za reproduktivnost.
parallel_chains	Broj lanaca koji se pokreću paralelno. Zadano: <code>min(chains, detectCores() - 1)</code> .
refresh	Učestalost ispisa napretka. 0 za tihi rad.

Vraća. Objekt klase `bdeb_fit` koji sadrži:

- `fit$fit` — sirovi `CmdStanMCMC` rezultat,
- `fit$model` — specifikacija modela,
- `fit$stan_model` — kompilirani Stan model,
- metapodaci o uzorkovanju.

Primjer.

```
fit <- bdeb_fit(mod, chains = 4, iter_sampling = 2000,
               adapt_delta = 0.9, seed = 42)

fit
# -- BDEB Fit ---
# i Model type: individual
# i Chains: 4, Warmup: 1000, Sampling: 2000
# v No divergent transitions
```

10 Dijagnostika konvergencije

10.1 bdeb_diagnose() — MCMC dijagnostika

Funkcija `bdeb_diagnose()` ispisuje sveobuhvatno izvješće o konvergenciji i automatski označava problematične vrijednosti.

```
bdeb_diagnose(fit, pars = NULL)
```

Izvješće uključuje:

- **Divergentni prijelazi** — prijelazi u kojima je NUTS sampler naišao na prijelom u geometriji posteriorne distribucije. Idealno: 0.
- **Zasićenje dubine stabla** — situacije u kojima je NUTS dosegao `max_treedepth`.
- **E-BFMI** (energetski Bayesovski indeks frakcije nedostajuće informacije) — vrijednosti < 0.3 ukazuju na neučinkovito uzorkovanje.
- $\hat{R}$ — mjera konvergencije lanaca. Vrijednosti > 1.01 ukazuju na nedovoljnu konvergenciju.
- **ESS (bulk i tail)** — efektivna veličina uzorka. Vrijednosti < 400 upozoravaju na nedovoljno uzorkovanje.

```
diag <- bdeb_diagnose(fit)
# -- BDEB Diagnostics ---
# v No divergent transitions.
# v Treedepth OK.
# v E-BFMI OK (all > 0.3).
# -- Parameter Summary ---
# v All R-hat < 1.01.
# v Bulk ESS adequate (>400) for all parameters.
#   variable  mean    sd median    q5    q95  rhat  ess_bulk  ess_tail
#   p_Am      4.97  0.18   4.96  4.68  5.27  1.00    3240    2890
#   p_M       0.51  0.04   0.51  0.44  0.57  1.00    2780    2560
#   ...
```

Vraća (nevidljivo). Lista s komponentama: `n_divergent`, `n_max_treedepth`, `ebfmi`, `summary`.

10.2 bdeb_summary() — Posteriorna sumarizacija

Funkcija `bdeb_summary()` vraća urednu tablicu posteriornih izvlačenja.

```
bdeb_summary(fit, pars = NULL, prob = 0.90)
```

Argumenti.

pars Vektor imena parametara. Zadano: svi parametri modela.

prob Širina intervala vjerodostojnosti. Zadano 0.90 (5. i 95. percentil).

```
# Svi parametri s 90% intervalom vjerodostojnosti
bdeb_summary(fit)

# Odabrani parametri s 95% intervalom
bdeb_summary(fit,
  pars = c("p_Am", "p_M", "kappa"),
  prob = 0.95)

# Funkcionira i preko S3 metode:
summary(fit)
```

11 Izvedene veličine

11.1 bdeb_derived() — Biološki značajne izvedene veličine

Funkcija `bdeb_derived()` izračunava izvedene veličine iz posteriornih izvlačenja, automatski propagirajući nesigurnost.

```
bdeb_derived(fit, quantities = c("L_inf", "k_M",  
                                "growth_rate"), f = 1.0)
```

Dostupne veličine:

- "L_inf" — konačna strukturna duljina: $L_\infty = f \kappa \{p_{Am}\} / [p_M]$.
- "k_M" — konstanta stope somatskog održavanja: $k_M = [p_M] / [E_G]$.
- "growth_rate" — von Bertalanffyjeva stopa rasta: $\dot{k} = \frac{v}{3} \frac{[p_M]}{\kappa [E_G]}$.

Vraća. Objekt `posterior::draws_df` s jednim stupcem po traženoj veličini i jednim retkom po posteriornom izvlačenju.

```
derived <- bdeb_derived(fit,  
  quantities = c("L_inf", "growth_rate"))  
  
# Sumarizacija izvedenih velicina  
posterior::summarise_draws(derived,  
  "mean", "sd",  
  "q5" = ~quantile(.x, 0.05),  
  "q95" = ~quantile(.x, 0.95))  
#   variable      mean      sd      q5      q95  
#   L_inf        7.46    0.32    6.93    7.99  
#   growth_rate  0.0033  0.0004  0.0027  0.0040  
  
# Razliciti uvjeti hranjenja  
bdeb_derived(fit,  
  quantities = "L_inf", f = 0.7) # smanjena hrana
```

12 Posteriorne prediktivne provjere (PPC)

12.1 bdeb_ppc() — Provjera modela

Posteriorne prediktivne provjere uspoređuju podatke generirane iz posteriornog prediktivnog modela s opaženim podacima. Stan modeli generiraju replicirane podatke u bloku `generated quantities`.

```
bdeb_ppc(fit, type = c("growth", "reproduction", "all"))
```

Vraća. Objekt klase `bdeb_ppc` koji sadrži:

- `growth$L_obs` — opažene duljine,
- `growth$L_rep` — matrica repliciranih duljina (redovi = izvlačenja, stupci = opažanja),
- `growth$t_obs` — vremena opažanja.

```
ppc <- bdeb_ppc(fit, type = "growth")  
ppc  
# -- BDEB Posterior Predictive Check ---  
# i Type: growth  
# > Growth: 13 observations, 4000 posterior draws  
  
# Vizualizacija
```

```
plot(ppc, n_draws = 100)
```

12.2 bdeb_predict() i predict.bdeb_fit() — Predikcije

Generira posteriorne prediktivne trajektorije.

```
bdeb_predict(fit, newdata = NULL, n_draws = 200)
# ili ekvivalentno:
predict(fit, n_draws = 200)
```

```
pred <- predict(fit, n_draws = 100)
# pred$t       - vremenski niz
# pred$L_hat   - matrica predviđenih duljina
# pred$n_draws - broj izvlačenja
```

13 Vizualizacija

BayesianDEB nudi raznolike grafičke prikaze za dijagnostiku, interpretaciju i publikaciju. Svi grafovi vraćaju objekte paketa **ggplot2** koji se mogu dalje prilagođavati.


13.1 plot(fit, type = ...) — Grafički prikazi procjene

```
plot(fit, type = c("trace", "posterior", "pairs",
                  "trajectory"),
     pars = NULL, n_draws = 100)
```

13.1.1 Trace grafovi

Prikazuju MCMC lance kroz iteracije za vizualnu procjenu konvergencije. Lanci koji se dobro miješaju trebaju izgledati kao “dlakavi crvi” koji se preklapaju.

```
plot(fit, type = "trace")
# Odabrani parametri
plot(fit, type = "trace",
     pars = c("p_Am", "kappa", "sigma_L"))
```



Slika 5: Primjeri trace grafova. Lijevo: tri lanca se dobro miješaju (konvergencija). Desno: lanci se ne preklapaju (nedovoljna konvergencija, $\hat{R} > 1.01$).

13.1.2 Posteriorne gustoće

Preklopljene marginalne posteriorne distribucije po lancima.

```
plot(fit, type = "posterior")
plot(fit, type = "posterior",
     pars = c("p_Am", "p_M", "kappa"))
```

13.1.3 Dijagrami parova

Bivarijatni dijagrami rasipanja koji prikazuju posteriorne korelacije između parametara. Korisni za otkrivanje degeneracija i jakih korelacija.

```
plot(fit, type = "pairs",
     pars = c("p_Am", "p_M", "kappa"))
```

13.1.4 Trajektorije

Posteriorno predviđene krivulje rasta preklopljene s opaženim podacima.

```
plot(fit, type = "trajectory", n_draws = 200)
# Plave linije = posteriorna predviđanja
# Crne točke = opaženi podaci
```


13.2 plot(ppc) — Grafički prikaz PPC-a

```
ppc <- bdeb_ppc(fit, type = "growth")
plot(ppc, n_draws = 50)
# Sive linije = replicirane trajektorije
# Crvene točke = opaženi podaci
```

Za reprodukciju, PPC grafikon prikazuje histogram repliciranih brojeva potomaka s okomitim linijama za opažene vrijednosti.

14 DEBtox: Ekotoksikološki modeli

DEBtox modeli kombiniraju DEB energetiku s toksikokinetičko-toksikodinamičkim (TKTD) okvirom za procjenu učinaka kemikalija na organizme.



Slika 6: Shema TKTD okvira u DEBtox modelu. Vanjska koncentracija ulazi u organizam i uzrokuje unutarnju štetu D_w iznad praga NEC (z_w). Šteta se prevodi u faktor stresa s koji smanjuje asimilaciju.

14.1 Teorijska pozadina

Model dodaje varijablu skalirane unutarnje štete D_w čija dinamika slijedi:

$$\frac{dD_w}{dt} = k_d(\max(C_w - z_w, 0) - D_w), \quad (7)$$

gdje je k_d stopa oporavka od štete, z_w je koncentracija bez učinka (NEC — No Effect Concentration), a C_w je vanjska koncentracija.

Faktor stresa koji djeluje na asimilaciju:

$$s = b_w \cdot \max(D_w, 0), \quad \dot{p}_A = f\{p_{Am}\} L^2 \cdot \max(1 - s, 0). \quad (8)$$

U stacionarnom stanju $D_w = \max(C_w - z_w, 0)$, pa se EC_{50} izračunava analitički:

$$EC_{50} = z_w + \frac{0.5}{b_w}. \quad (9)$$

14.2 Dodatni DEBtox parametri

Tablica 6: Parametri specifični za DEBtox model.

Simbol	R ime	Jedinice	Opis
k_d	k_d	d ⁻¹	Stopa oporavka od štete
z_w	z_w	konc. jedinice	NEC (koncentracija bez učinka)
b_w	b_w	1/konc. jedinice	Intenzitet učinka

14.3 bdeb_tox() — Specifikacija DEBtox modela

Pogodnosna ovojnica oko `bdeb_model()` s `type = "debtox"`.

```
bdeb_tox(data, stress = c("assimilation", "maintenance",
                          "growth_cost"), priors = list(), ...)
```

Trenutačno je implementiran samo stres na asimilaciju. Buduće verzije uključit će stres na održavanje i trošak rasta.


```
data(debttox_growth)

conc_map <- setNames(
  c(0, 20, 80, 200),
  as.character(unique(debttox_growth$concentration)))
)

dat_tox <- bdeb_data(
  growth = debttox_growth,
  concentration = conc_map
)

mod_tox <- bdeb_tox(dat_tox, stress = "assimilation",
  priors = list(
    z_w = prior_lognormal(mu = 2.5, sigma = 1.0),
    b_w = prior_lognormal(mu = -5.0, sigma = 2.0)
  ))

fit_tox <- bdeb_fit(mod_tox, chains = 4,
  adapt_delta = 0.95, seed = 77)
```



Slika 7: Krivulja doza-odgovor generirana funkcijom `plot_dose_response()`. Plave prozirne linije prikazuju posteriorne izvlačenja funkcije stresa. Vertikalne isprekidane linije označavaju NEC (zeleno) i EC_{50} (crveno).

14.4 `bdeb_ec50()` — Ekstrakcija EC_{50} i NEC

Ekstrahira posteriornu distribuciju EC_{50} i NEC iz procijenjenog DEBtox modela.

```
bdeb_ec50(fit, prob = 0.90)
```

Vraća. Lista s komponentama:

- `draws` — posteriorna izvlačenja EC_{50} ,
- `summary` — podatkovni okvir s mean, median, sd, lower, upper,
- `NEC` — sumarijacija koncentracije bez učinka.

```
result <- bdeb_ec50(fit_tox, prob = 0.95)
# -- DEBtox Effect Concentrations ---
#   parameter mean median   sd lower upper
#   EC50      181.7  180.2  12.4 159.3 204.1
#   NEC       15.3   15.1   2.1  11.8  19.2

# Pristup posteriornim izvlačenjima
hist(result$draws, breaks = 40,
      main = "Posteriorna distribucija EC50",
      xlab = "Koncentracija")
```

14.5 `plot_dose_response()` — Krivulja doza-odgovor

Prikazuje funkciju stresa preko kontinuiranog raspona koncentracija s pojasima posteriorne nesigurnosti.

```
plot_dose_response(fit, endpoint = "growth",
                  n_draws = 100)
```


```
plot_dose_response(fit_tox, n_draws = 200)
# Plave linije = posteriorna predviđanja stresa
# Crvene točke = opazene relativne vrijednosti
# Isprekidana linija = 50% efekta (za EC50)
```

15 Pomoćne funkcije

15.1 `arrhenius()` — Arrheniusova temperaturna korekcija

Izračunava korekcijski faktor za DEB parametre stope na temelju Arrheniusovog odnosa:

$$c_T = \exp\left(\frac{T_A}{T_{\text{ref}}} - \frac{T_A}{T}\right). \quad (10)$$



Slika 8: Arrheniusov korekcijski faktor c_T u ovisnosti o temperaturi za tri vrijednosti Arrheniusove temperature T_A . Pri referentnoj temperaturi (20°C) faktor je uvijek 1.

```
arrhenius(T, T_ref = 293.15, T_A = 8000)
```

```
# Pri referentnoj temperaturi (20 C): faktor = 1
arrhenius(293.15)
# [1] 1

# Pri 25 C (5 stupnjeva toplije): faktor > 1
arrhenius(298.15)
# [1] 1.741

# Pri 15 C (5 stupnjeva hladnije): faktor < 1
arrhenius(288.15)
# [1] 0.552

# Prilagodeni Arrheniusov parametar
arrhenius(298.15, T_ref = 293.15, T_A = 6000)
```

15.2 `deb_fluxes()` — Izračun DEB energetskih tokova

Za zadano trenutačno stanje (E, V) i parametre izračunava sve standardne DEB energetske tokove.

```
deb_fluxes(E, V, f, p_Am, p_M, kappa, v, E_G,
            k_J = 0, E_Hp = 0)
```

Vraća. Imenovana lista s tokovima: p_A (asimilacija), p_C (mobilizacija), p_M (somatsko održavanje), p_G (rast), p_J (održavanje zrelosti), p_R (reprodukcija), te izvedene veličine L (strukturna duljina) i e (skalirana gustoća rezervi).

```

fl <- deb_fluxes(E = 10, V = 0.5, f = 1.0,
                 p_Am = 5, p_M = 0.5, kappa = 0.75,
                 v = 0.2, E_G = 400)

fl$p_A # tok asimilacije
fl$p_C # tok mobilizacije
fl$p_M # tok somatskog održavanja
fl$p_G # tok rasta
fl$L   # strukturna duljina =  $V^{(1/3)}$ 
fl$e   # skalirana gustoca rezervi

# Primjer za organizam s reprodukcijom
fl2 <- deb_fluxes(E = 50, V = 2.0, f = 1.0,
                  p_Am = 5, p_M = 0.5, kappa = 0.75,
                  v = 0.2, E_G = 400,
                  k_J = 0.002, E_Hp = 50)
fl2$p_R # tok reprodukcije
fl2$p_J # tok održavanja zrelosti

```

16 Ugrađeni skupovi podataka

Paket uključuje tri simulirana skupa podataka za demonstraciju i testiranje.

16.1 eisenia_growth

Simulirani podaci o rastu za 21 jedinku gliste *Eisenia fetida* mjerenu tjedno kroz 12 tjedana (dani 0, 7, 14, ..., 84).

Redaka 273 (21 jedinka $\times$ 13 vremenskih točaka).

Stupci id (cijeli broj 1–21), time (dani), length (cm).


Stvarni parametri $\{p_{Am}\} = 5.0$, $[p_M] = 0.5$, $\kappa = 0.75$, $v = 0.2$, $[E_G] = 400$; individualna varijacija u $\{p_{Am}\}$ ($CV \approx 10\%$) i L_0 ($CV \approx 5\%$); $\sigma_L = 0.015$ cm.

```

data(eisenia_growth)
head(eisenia_growth)
str(eisenia_growth)

# Vizualizacija
library(ggplot2)
ggplot(eisenia_growth, aes(time, length, group = id)) +
  geom_line(alpha = 0.4) +
  theme_bw() +
  labs(x = "Vrijeme (dani)", y = "Strukturna duljina (cm)")

```



Slika 9: Ilustracija podataka `eisenia_growth`: krivulje rasta za 21 jedinku gliste *Eisenia fetida* s individualnom varijacijom u stopi asimilacije.

16.2 folsomia_repro

Simulirani podaci o reprodukciji skočibube *Folsomia candida* izložene 5 koncentracija kadmija (0, 10, 50, 100, 500 mg/kg) s 6 replikata po koncentraciji.

Redaka 30 (5 koncentracija $\times$ 6 replikata).

Stupci `id`, `concentration`, `t_start`, `t_end`, `count`.

Stvarni parametri $NEC = 30$ mg/kg, $b_w = 0.005$, bazni broj potomaka = 120.

```
data(folsomia_repro)
head(folsomia_repro)

# Vizualizacija doza-odgovor
ggplot(folsomia_repro,
       aes(factor(concentration), count)) +
  geom_boxplot() +
  theme_bw() +
  labs(x = "Koncentracija Cd (mg/kg)",
       y = "Broj potomaka")
```

16.3 debtox_growth

Simulirani podaci o rastu pod izloženosti toksikantu: 4 koncentracijske grupe (0, 20, 80, 200), 10 jedinki po grupi, tjedno mjerenje kroz 6 tjedana.


Redaka 280 (40 jedinki $\times$ 7 vremenskih točaka).

Stupci `id`, `concentration`, `time`, `length`.

Stvarni parametri $NEC = 15$, $b_w = 0.003$, stres na asimilaciju.


```
data(debtox_growth)
head(debtox_growth)

ggplot(debtox_growth,
       aes(time, length, colour = factor(concentration),
          group = id)) +
  geom_line(alpha = 0.4) +
  theme_bw() +
  labs(x = "Vrijeme (dani)", y = "Strukturna duljina (cm)",
       colour = "Koncentracija")
```



Slika 10: Ilustracija podataka `debttox_growth`: srednje krivulje rasta pod četiri koncentracije toksikanta. Veća koncentracija uzrokuje veću inhibiciju rasta putem smanjene asimilacije.

17 Cjeloviti primjeri: Radni tokovi za sve tipove modela



Slika 11: Lijevo: posteriorne trajektorije rasta (plave linije) s opaženim podacima (crne točke). Desno: posteriorna prediktivna provjera — replicirani podaci (sive linije) trebaju obuhvatiti opažanja (crvene točke).

17.1 Primjer 1: Individualni model rasta

Ovaj primjer pokazuje kompletni radni tok za procjenu DEB parametara jedne jedinice gliste *Eisenia fetida*.

```
library(BayesianDEB)

# =====
# Korak 1: Priprema podataka
# =====
data(eisenia_growth)

# Odabir jedne jedinice
df1 <- eisenia_growth[eisenia_growth$id == 1, ]
dat <- bdeb_data(growth = df1, f_food = 1.0)
dat
```

```

# =====
# Korak 2: Specifikacija modela
# =====
mod <- bdeb_model(dat, type = "individual",
  priors = list(
    p_Am = prior_lognormal(mu = 1.5, sigma = 0.5),
    p_M = prior_lognormal(mu = -1.0, sigma = 0.5),
    kappa = prior_beta(a = 3, b = 2),
    sigma_L = prior_halfnormal(sigma = 0.05)
  ))
mod # ispisuje specifikaciju ukljucujuci sve priore

# =====
# Korak 3: Procjena putem MCMC
# =====
fit <- bdeb_fit(mod, chains = 4, iter_sampling = 2000,
  adapt_delta = 0.9, seed = 42)
fit # ispisuje brzu dijagnosticku sumrizaciju

# =====
# Korak 4: Dijagnostika konvergencije
# =====
bdeb_diagnose(fit)
# Provjeriti:
# - Nema divergentnih prijelaza
# - Svi R-hat < 1.01
# - Bulk ESS > 400 za sve parametre

# Trace grafovi
plot(fit, type = "trace")

# Posteriorne korelacije
plot(fit, type = "pairs",
  pars = c("p_Am", "p_M", "kappa"))

# =====
# Korak 5: Posteriorna sumrizacija
# =====
bdeb_summary(fit, prob = 0.95)

# =====
# Korak 6: Izvedene velicine
# =====
bdeb_derived(fit, quantities = c("L_inf", "growth_rate"))


# =====
# Korak 7: Posteriorna prediktivna provjera
# =====
ppc <- bdeb_ppc(fit, type = "growth")
plot(ppc, n_draws = 100)

# =====
# Korak 8: Grafikon trajektorija
# =====
plot(fit, type = "trajectory", n_draws = 200)

```


17.2 Primjer 2: Hijerarhijski model s više jedinki

Hijerarhijski model koristi se kada imamo podatke za više jedinki i želimo procijeniti populacijske distribucije parametara uz djelomično spajanje (eng. partial pooling). Model koristi necentriranu parametrizaciju za individualne varijacije u $\{p_{Am}\}$.



Slika 12: Struktura hijerarhijskog modela. Populacijski hiperparametri ($\mu_{\log p_{Am}}$, $\sigma_{\log p_{Am}}$) generiraju individualne stope asimilacije putem necentrirane parametrizacije. Dijeljeni parametri (p_M, κ, v, E_G) utječu na sve jedinke jednako.

```
library(BayesianDEB)
data(eisenia_growth)

# =====
# Korak 1: Priprema (svih 21 jedinka)
# =====
dat_all <- bdeb_data(growth = eisenia_growth, f_food = 1.0)
dat_all
# => 21 jedinka, 273 opazanja

# =====
# Korak 2: Specifikacija hijerarhijskog modela
# =====
# Necentrirana parametrizacija automatski je
# implementirana u Stan modelu
mod_h <- bdeb_model(dat_all, type = "hierarchical",
  priors = list(
    mu_log_p_Am = prior_normal(mu = 1.5, sigma = 0.5),
    sigma_log_p_Am = prior_exponential(rate = 2),
    kappa = prior_beta(a = 3, b = 2)
  ))
mod_h

# =====
# Korak 3: Procjena (veci adapt_delta za slozeni model)
# =====
fit_h <- bdeb_fit(mod_h, chains = 4, iter_sampling = 2000,
  adapt_delta = 0.95, seed = 123)

# =====
# Korak 4: Dijagnostika
# =====
bdeb_diagnose(fit_h)

# =====
```

```

# Korak 5: Populacijska sumarizacija
# =====
bdeb_summary(fit_h,
  pars = c("mu_log_p_Am", "sigma_log_p_Am",
           "p_M", "kappa", "v", "E_G"))

# =====
# Korak 6: Individualne stope asimilacije
# =====
bdeb_summary(fit_h,
  pars = paste0("p_Am_ind[", 1:21, "]"))

# =====
# Korak 7: Predikcija za novu (neopazenu) jedinku
# =====
# Stan model automatski generira p_Am_new u
# bloku generated quantities
bdeb_summary(fit_h, pars = "p_Am_new")

# =====
# Korak 8: Trace grafovi hijerarhijskih parametara
# =====
plot(fit_h, type = "trace",
  pars = c("mu_log_p_Am", "sigma_log_p_Am"))

plot(fit_h, type = "posterior",
  pars = c("mu_log_p_Am", "sigma_log_p_Am",
           "p_M", "kappa"))

```

17.3 Primjer 3: Model rasta i reprodukcije

Trodimenzionalni DEB model (E , V , R) procjenjuje istodobno parametre rasta i reprodukcije. Reproductivni podaci modeliraju se negativnom binomnom distribucijom za intervalske brojeve potomaka.

```

library(BayesianDEB)

# =====
# Korak 1: Priprema podataka
# =====
growth_df <- data.frame(
  id = 1, time = seq(0, 56, by = 7),
  length = c(0.10, 0.18, 0.28, 0.37, 0.44,
             0.49, 0.52, 0.54, 0.55)
)

repro_df <- data.frame(
  id      = 1,
  t_start = c(28, 35, 42, 49),
  t_end   = c(35, 42, 49, 56),
  count   = c(5, 12, 18, 15)
)

dat_gr <- bdeb_data(growth = growth_df,
  reproduction = repro_df,
  f_food = 1.0)

dat_gr

```

```

# =====
# Korak 2: Specifikacija modela
# =====
mod_gr <- bdeb_model(dat_gr, type = "growth_repro",
  priors = list(
    kappa = prior_beta(a = 3, b = 2),
    k_R    = prior_lognormal(mu = -2, sigma = 1),
    E_Hp   = prior_lognormal(mu = 2.0, sigma = 1.5)
  ))

# =====
# Korak 3: Procjena
# =====
fit_gr <- bdeb_fit(mod_gr, chains = 4,
  adapt_delta = 0.95, seed = 99)

# =====
# Korak 4: Dijagnostika i sumariizacija
# =====
bdeb_diagnose(fit_gr)
bdeb_summary(fit_gr)

# =====
# Korak 5: PPC za rast
# =====
plot(bdeb_ppc(fit_gr, type = "growth"))

# =====
# Korak 6: PPC za reprodukciju
# =====
plot(bdeb_ppc(fit_gr, type = "reproduction"))

```

Korištenje kumulativnih podataka. Ako su podaci o reprodukciji u kumulativnom obliku, prvo ih pretvorite:

```

cumul <- data.frame(
  id      = rep(1, 6),
  time    = c(0, 14, 21, 28, 35, 42),
  cumulative = c(0, 0, 8, 25, 48, 72)
)
intervals <- repro_to_intervals(cumul)
dat_gr2 <- bdeb_data(growth = growth_df,
  reproduction = intervals)

```

17.4 Primjer 4: DEBtox ekotoksikološki model

Četverodimenzionalni TKTD model (E , V , R , D_w) procjenjuje parametre DEB energetike i toksikološke parametre istodobno. Ovaj primjer koristi ugrađeni `debtox_growth` dataset.

```

library(BayesianDEB)

# =====
# Korak 1: Priprema podataka
# =====
data(debtox_growth)

# Mapiranje koncentracija

```

```

conc_map <- setNames(
  c(0, 20, 80, 200),
  as.character(unique(debtox_growth$concentration))
)

dat_tox <- bdeb_data(
  growth = debtox_growth,
  concentration = conc_map,
  f_food = 1.0
)
dat_tox

# =====
# Korak 2: Specifikacija DEBtox modela
# =====
mod_tox <- bdeb_tox(dat_tox, stress = "assimilation",
  priors = list(
    z_w = prior_lognormal(mu = 2.5, sigma = 1.0),
    b_w = prior_lognormal(mu = -5.0, sigma = 2.0),
    k_d = prior_lognormal(mu = -1.0, sigma = 1.0)
  ))
mod_tox

# =====
# Korak 3: Procjena
# =====
fit_tox <- bdeb_fit(mod_tox, chains = 4,
  adapt_delta = 0.95, seed = 77)

# =====
# Korak 4: Dijagnostika
# =====
bdeb_diagnose(fit_tox)

# =====
# Korak 5: EC50 i NEC s 95% intervalima
# =====
ec_result <- bdeb_ec50(fit_tox, prob = 0.95)
# -- DEBtox Effect Concentrations --
#   parameter mean median   sd lower upper
#   EC50    ...    ...    ...    ...    ...
#   NEC     ...    ...    ...    ...    ...

# Histogram posteriorne distribucije EC50
hist(ec_result$draws, breaks = 40,
  main = "Posteriorna distribucija EC50",
  xlab = "Koncentracija")

# =====
# Korak 6: Krivulja doza-odgovor
# =====
plot_dose_response(fit_tox, n_draws = 200)

# =====
# Korak 7: Sumarizacija toksikoloskih parametara
# =====
bdeb_summary(fit_tox,
  pars = c("p_Am", "p_M", "kappa",

```


```

    "k_d", "z_w", "b_w", "sigma_L"))

# =====
# Korak 8: Trace i posteriorne gustoće
# =====
plot(fit_tox, type = "trace",
     pars = c("k_d", "z_w", "b_w"))

plot(fit_tox, type = "posterior",
     pars = c("k_d", "z_w", "b_w"))

```



Slika 13: Bayesovska inferencija: prior (isprekidana plava) kodira prethodno znanje, vjerodostojnost (točkasta zelena) sadrži informaciju iz podataka, a posterior (crvena) je rezultat njihovog kombiniranja putem Bayesovog teorema. Posterior je uvijek uži od priora jer podaci pružaju dodatnu informaciju.

18 Detalji Stan modela

Ovaj odjeljak opisuje unutarnju strukturu ugrađenih Stan modela za korisnike koji žele razumjeti ili proširiti ih.

18.1 Desna strana DEB ODE sustava

Svi modeli dijele istu ODE funkciju koja implementira jednadžbe (1)–(5). Potpis funkcije u Stanu:

```

vector deb_growth_ode(real t, vector x,
  array[] real theta, array[] real env)

```

gdje je $\mathbf{x} = [E, V]'$, $\theta = \{p_{Am}, p_M, \kappa, v, E_G\}$, i $\text{env} = \{f\}$.

Stabilizacijski član $1e-12$ dodan je nazivniku mobilizacijskog toka kako bi se spriječilo dijeljenje nulom:

$$\dot{p}_C = \frac{E v L}{E + [E_G] V + 10^{-12}}. \quad (11)$$

18.2 Hiperparametri priora kao podaci

Hiperparametri priora prosljeđuju se iz R-a kao Stan `data` varijable (npr. `prior_p_Am_mu`, `prior_p_Am_sd`). To omogućuje korisnicima promjenu priora bez ponovnog kompiliranja Stan

modela.


18.3 Necentrirana parametrizacija hijerarhijskog modela

Hijerarhijski model koristi standardnu necentriranu parametrizaciju kako bi izbjegao geometriju lijevka:

$$z_j \sim \mathcal{N}(0, 1), \quad j = 1, \dots, N, \quad (12)$$

$$\log\{p_{Am}\}_j = \mu_{\log p_{Am}} + \sigma_{\log p_{Am}} \cdot z_j. \quad (13)$$

Ovo razdvaja populacijske parametre (μ , σ) od individualnih devijacija i značajno poboljšava učinkovitost HMC uzorkovanja.



Slika 14: Usporedba geometrije posteriorne distribucije. Lijevo: centrirana parametrizacija stvara geometriju lijevka koja otežava HMC uzorkovanje. Desno: necentrirana parametrizacija daje ravnomjerniju geometriju.

18.4 Generated quantities

Svi Stan modeli u bloku `generated quantities` generiraju:

- `L_rep` — replicirane duljine za posteriorne prediktivne provjere,
- `log_lik` — log-vjerodostojnost po opažanju (za usporedbu modela putem LOO-CV),
- `EC50`, `NEC` — samo za DEBtox model,
- `p_Am_new` — samo za hijerarhijski model (predikcija za novu jedinku).

19 Praktični savjeti

19.1 Odabir `adapt_delta`

Počnite s `adapt_delta = 0.8` (zadano). Ako `bdeb_diagnose()` prijavi divergentne prijelaze, povećajte na 0.9, 0.95 ili čak 0.99. Više vrijednosti usporavaju uzorkovanje, ali poboljšavaju geometrijsku vjernost.

```
# Pocetni pokusaj
fit <- bdeb_fit(mod, adapt_delta = 0.8)
bdeb_diagnose(fit) # ako ima divergencija:

# Povecani adapt_delta
fit <- bdeb_fit(mod, adapt_delta = 0.95)
```

19.2 Kada koristiti hijerarhijski model

Koristite `type = "hierarchical"` kada:

- Imate podatke za više od 3–4 jedinke.
- Želite procijeniti populacijske distribucije parametara.
- Neke jedinke imaju rijetke podatke (djelomično spajanje pomaže).
- Trebate predikcije za nove, neopažene jedinke.

19.3 Osjetljivost na priore

Uvijek usporedite rezultate pod barem dvije vjerodostojne specifikacije priora. Parametri koji ostaju dominirani priorom (posteriorna distribucija $\approx$ priorna distribucija) slabo su identificirani i trebaju se tako prijaviti.

```
# Specifikacija 1: siri priori
mod1 <- bdeb_model(dat, type = "individual",
  priors = list(
    p_Am = prior_lognormal(mu = 1.5, sigma = 1.0)
  ))

# Specifikacija 2: uzi priori
mod2 <- bdeb_model(dat, type = "individual",
  priors = list(
    p_Am = prior_lognormal(mu = 1.5, sigma = 0.3)
  ))

fit1 <- bdeb_fit(mod1, seed = 42)
fit2 <- bdeb_fit(mod2, seed = 42)

# Usporedba posteriornih sumarijacija
bdeb_summary(fit1, pars = "p_Am")
bdeb_summary(fit2, pars = "p_Am")
```

19.4 Računalni savjeti

- Kompilacija Stan modela je spora prvi put (~ 30 s), ali se kešira za buduće procjene.
- Koristite `parallel_chains = 4` za paralelno pokretanje lanaca.
- Za velike hijerarhijske modele, počnite s podskupom jedinki za testiranje parametrizacije, zatim proširite.
- Ako ODE rješavač zakaže, provjerite početne uvjete (E0, L0) i osigurajte da su biološki razumne.
- Za tihi rad koristite `refresh = 0`.

20 Usporedba s postojećim alatima

21 Pregled svih eksportiranih funkcija

Funkcija	Kategorija	Opis
<code>bdeb_data()</code>	Priprema	Validira i strukturira ulazne podatke
<code>repro_to_intervals()</code>	Priprema	Pretvara kumulativnu u intervalsku reprodukciju
<code>prior_lognormal()</code>	Priori	Log-normalna priorna distribucija
<code>prior_normal()</code>	Priori	Normalna priorna distribucija

Funkcija	Kategorija	Opis
prior_beta()	Priori	Beta priorna distribucija
prior_halfnormal()	Priori	Polu-normalna priorna distribucija
prior_halfcauchy()	Priori	Polu-Cauchyjeva priorna distribucija
prior_exponential()	Priori	Eksponecijalna priorna distribucija
prior_default()	Priori	Zadani slabo informativni priori
obs_normal()	Opažanja	Gaussovska pogreška
obs_lognormal()	Opažanja	Log-normalna pogreška
obs_student_t()	Opažanja	Studentova t pogreška
obs_poisson()	Opažanja	Poissonova distribucija
obs_negbinom()	Opažanja	Negativna binomna distribucija
bdeb_model()	Specifikacija	Kombinira podatke, tip, priore, opažanja
bdeb_tox()	Specifikacija	Pogodnosna ovojnica za DEBtox
bdeb_fit()	Procjena	MCMC uzorkovanje putem cmdstanr-a
bdeb_diagnose()	Dijagnostika	Konvergencija, R-hat, ESS, E-BFMI
bdeb_summary()	Dijagnostika	Posteriorna sumarijacija parametara
bdeb_derived()	Dijagnostika	Izvedene biološke veličine
bdeb_ppc()	PPC	Posteriorne prediktivne provjere
bdeb_predict()	Predikcija	Posteriorne prediktivne trajektorije
bdeb_ec50()	DEBtox	Ekstrakcija EC50 i NEC
plot_dose_response()	DEBtox	Krivulja doza-odgovor
arrhenius()	Pomoćne	Arrheniusova temperaturna korekcija
deb_fluxes()	Pomoćne	Izračun DEB energetskih tokova
plot.bdeb_fit	S3 metoda	Trace, posterior, pairs, trajectory
plot.bdeb_ppc	S3 metoda	Vizualizacija PPC-a
print.bdeb_data	S3 metoda	Ispis sumarijacije podataka
print.bdeb_model	S3 metoda	Ispis specifikacije modela
print.bdeb_fit	S3 metoda	Ispis rezultata procjene
print.bdeb_ppc	S3 metoda	Ispis PPC sumarijacije
summary.bdeb_fit	S3 metoda	Poziva bdeb_summary()
predict.bdeb_fit	S3 metoda	Poziva bdeb_predict()

Literatura

- Kooijman, S.A.L.M. (2010). *Dynamic Energy Budget Theory for Metabolic Organisation*. Cambridge University Press. doi:10.1017/CB09780511805400
- Carpenter, B. et al. (2017). Stan: A Probabilistic Programming Language. *Journal of Statistical Software*, 76(1).
- Gelman, A. et al. (2020). *Bayesian Data Analysis*, 3rd ed. Chapman & Hall/CRC.
- Jager, T. & Zimmer, E.I. (2012). Simplified Dynamic Energy Budget model for analysing ecotoxicity data. *Ecological Modelling*, 225, 74–81.

Tablica 7: Usporedba paketa **BayesianDEB** s postojećim alatima za DEB kalibraciju.

Značajka	AmP/DEBtool	deBIInfer	Ručni Stan	BayesianDEB
Bayesovska inferencija	–	Da	Da	Da
Ugrađeni DEB modeli	Da	–	–	Da
Hijerarhijski modeli	–	–	Ručno	Ugrađeno
DEBtox (TKTD)	Djelomično	–	Ručno	Ugrađeno
API za priore	–	Osnovni	Ručno	Bogat
Dijagnostika	Minimalna	Osnovna	Ručno	Automatska
PPC	–	–	Ručno	Ugrađeno
R paket	MATLAB+R	Da	–	Da